BABEȘ-BOLYAI UNIVERSITY, CLUJ NAPOCA, ROMÂNIA

FACULTY OF MATHEMATICS AND COMPUTER SCIENCE

Raport în vederea studierii modelelor de Machine Learning cu scopul determinării riscului de MGLA în cancerul mamar

Maria Podea, Teodora Călugărițoiu, Daria Crețt

2026

1 Introducere

Detectarea cancerului de sân în mamografii este o problemă critică în imagistica medicală și diagnostic. Interpretarea mamografiilor este provocatoare din cauza variațiilor în densitatea țesuturilor, a structurilor suprapuse și a diferențelor subtile dintre tumorile benigne și maligne. Această problemă trebuie rezolvată folosind un algoritm inteligent, deoarece examinarea manuală tradițională de către radiologi este consumatoare de timp și predispusă la erori umane.

Cancerul de sân este cea mai frecventă formă de cancer la femei și a doua cauză a deceselor provocate de tumorile maligne, după cancerul de plămân, în populația feminină. Boala se declanșează atunci când unele celule din structura glandei mamare capătă anumite mutații la nivel genetic și se înmulțesc incontrolabil, formând o tumoră.

Se estimeaza că 1 din 8 femei va fi diagnosticata de-a lungul vieții cu această boală. Însa cancerul de sân nu este apanajul doar al femeilor, el fiind întâlnit, rar, și la barbați. La nivel global, 1,7 milioane de cazuri de cancer mamar sunt diagnosticate anual și mai mult de 500 000 paciente decedează din această cauza; numarul cazurilor la barbați reprezintă 1 procent din total.

Europa continuă să constituie unul dintre continentele cu cea mai crescută incidență a cancerului de sân. Deși constituie o suferință extrem de traumatizantă pentru femei, cancerul mamar poate fi prevenit și, dacă este descoperit în stadii incipiente, se tratează și se vindecă.

1.1 Scopul aplicației

Aplicația propusă are ca scop asistarea medicilor în evaluarea riscului de apariție a metastazei ganglionare limfatice axilare (MGLA) în cancerul mamar. Acest lucru este util mai ales în contextul în care descoperirea timpurie a afecțiunii poate oferi diversitate în opțiunile de tratament și șanse ridicate de vindecare.

1.2 Descrierea aplicației

Deoarece utilizatorul aplicației cel mai probabil nu va avea un profil tehnic, ci va face parte din industria medicală, am decis să păstrăm un design intuitiv al aplicației și pași simpli în navigarea acesteia. Astfel, când se deschide aplicația, vor fi afișate două butoane: unul care facilitează încărcarea mamografiei dorite, iar cel de-al doilea care va iniția analiza. După ce sunt încărcate datele și este pornită simularea, în colțul din stânga jos va apărea probabilitatea găsită de algoritm cu privire la riscul detectării unei posibile MGLA.

2 Analiza literaturii de specialitate

2.1 Predicția metastazelor ganglionare axilare bazată pe parametri clinici si ecografici

În această lucrare [6], autorii propun un model de predicție a metastazelor ganglionare axilare (ALNM) folosind un set de date provenit de la 1671 de paciente cu cancer mamar operabil (împărțit în 900 de date pentru antrenare si 761 pentru testare). Datele îmbină trăsături clinico-patologice (vârstă, IMC, palpabilitate) cu parametri de ecografie de înaltă frecvență (dimensiunea tumorii, infiltrarea țesutului adipos etc.). Ca algoritmi de AI, s-a utilizat algoritmul de clasificare bazat pe arbori de decizie C5.0, alături de analize de regresie logistică. Modelele au înregistrat o acuratete de 69.52% si o rată de fals-negative (FNR) de 74.18%.

2.2 Straturi de Cross-Attention pentru fuziunea trăsăturilor (Feature Fusion)

Această lucrare [4] detaliază un mecanism neuronal de tip *Cross-Attention*, care este o componentă arhitecturală esențială pentru abordarea noastră de a îmbina cele două tipuri de date eterogene (imagini și text). Fiind un studiu axat pe arhitectură, formalizează matematic algoritmul AI prin care se face transferul selectiv de informatii între domeniile de date folosind proiecții de tip Query, Key si Value ($Q = XW_Q, K = YW_K, V = YW_V$).

2.3 "Segment Anything" (SAM) [2]

Lucrarea introduce modelul SAM pentru segmentarea imaginilor bazat pe prompturi (punct, bounding box, mască, text). Arhitectura îmbină

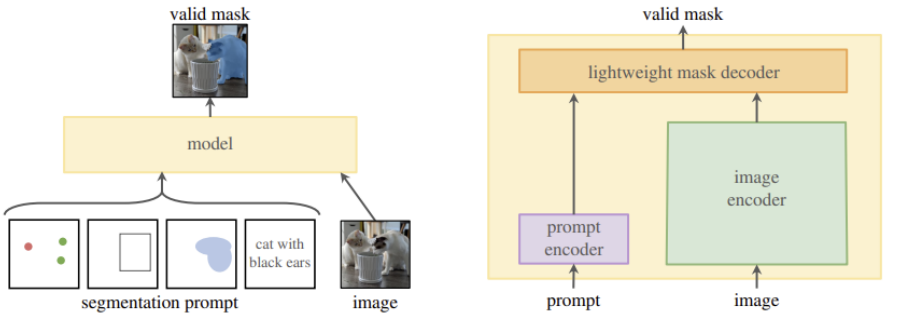
3 componente principale:

1. image encoder - vision transformer adaptat pentru procesarea datelor de intrare la rezoluție mare

2. prompt encoder - promptul este reprezentat prin positional encoding. În cazul în care prompt-ul este dat sub formă de mască, embedding-ul se obține prin aplicarea de covoluții.

3. mask decoder - transformer decoder urmat de mask prediction head, care generează măștile de segmentare combinând embedding-urile imaginilor și prompturilor

Modelul a fost antrenat pe SA-1B, un set de date conținând 11 milioane de imagini și 1 miliard de măști de segmentare. Datele au fost colectate pe parcursul dezvoltării modelului, în 3 etape: manual asistat, semi automat, complet automat. SAM a obținut un Dice Score de 96% in segmentarea pulmonară.



(a) **Task**: promptable segmentation (b) **Model**: Segment Anything Model (**SAM**)

Figure 1: Imagine preluată din [2].

2.4 "An Image is Worth 16x16 Words" (ViT) [1]

Această lucrare demonstreaza că arhitectura transformer, folosită inițial în procesarea limbajului natural, poate fi utilizată cu succes în computer vision. Vision Transformer tratează o imagine ca pe o secvență de 'patch-uri', similar modului de procesare a cuvintelor dintr-o propoziție. Fiecare patch este transformat într-un vector (patch embedding) și procesat de un transformer encoder, folosind mecanismul de self attention. Pentru păstrarea informațiilor spațiale, la patch embeddings se adaugă positional embeddings.

Ca alternativă la utilizarea de imagini ca input, se propune o arhitectură hibridă, unde input-ul este format dintr-o serie de feature-uri extrase de un CNN.

ViT antrenat pe un volum mare de date depășește performanța abordării bazate pe convoluții, însă pe un set de date limitat performanța scade semnificativ, sub cea obținută de ResNet.

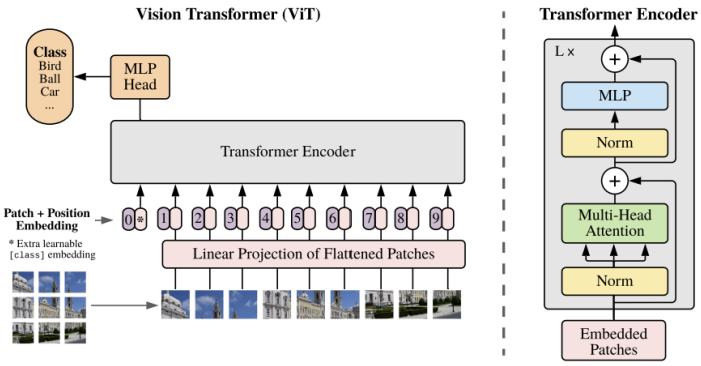


Figure 1: Model overview. We split an image into fixed-size patches, linearly embed each of them, add position embeddings, and feed the resulting sequence of vectors to a standard Transformer encoder. In order to perform classification, we use the standard approach of adding an extra learnable "classification token" to the sequence. The illustration of the Transformer encoder was inspired by Vaswani et al. (2017).

Figure 2: Imagine preluată din [1].

2.5 Model Hibrid CNN-ViT

Ambele tehnologii sunt utilizate în procesarea imaginilor (atât rețelele neuronale convoluționale - CNN, cât și Vision Transformer), însă au abordări, calități și defecte diferite. Anterior s-a discutat mai în detaliu soluția ViT, care se bazează exclusiv pe mecanismul de atenție, dar care da dovadă de anumite neajunsuri în cazul studierii mamografiilor: poate rata texturile fine precum microcalcificările. Din acest motiv este necesar ca marginile și texturile unei posibile tumori să fie precis extrase și abia apoi trimise către ViT. Acest lucru se poate realiza prin utilizarea CNN.

Totuși, se pot aduce îmbunătățiri și acestui model hibrid, prin introducerea unui Inception Model. Soluția propusă în articolul [5], denumită RI-ViT, se bazează pe trei părți esențiale: extragerea feature-urilor locale prin intermediul CNN, îmbogățirea și combinarea caracteristicilor (Inception Model), extragerea feature-urilor globale (ViT). Adăugarea unui Inception Model reușește să mărească acuratețea și robustețea modelului, având rol în combinarea feature-urilor de dimensiuni și din contexte diferite. Acest aspect este deosebit de important în sarcinile complexe de recunoaștere a tiparelor, precum clasificarea imaginilor histopatologice, unde precizia este crucială. După un studiu în care s-au utilizat diverse niveluri de magnificație, modelul a obținut cele mai bune rezultate la o magnificație de 40X:

- acuratețe de 99.75%
- precizie de 100%
- rapel de 99.65%
- scorul F1 de 99.82%

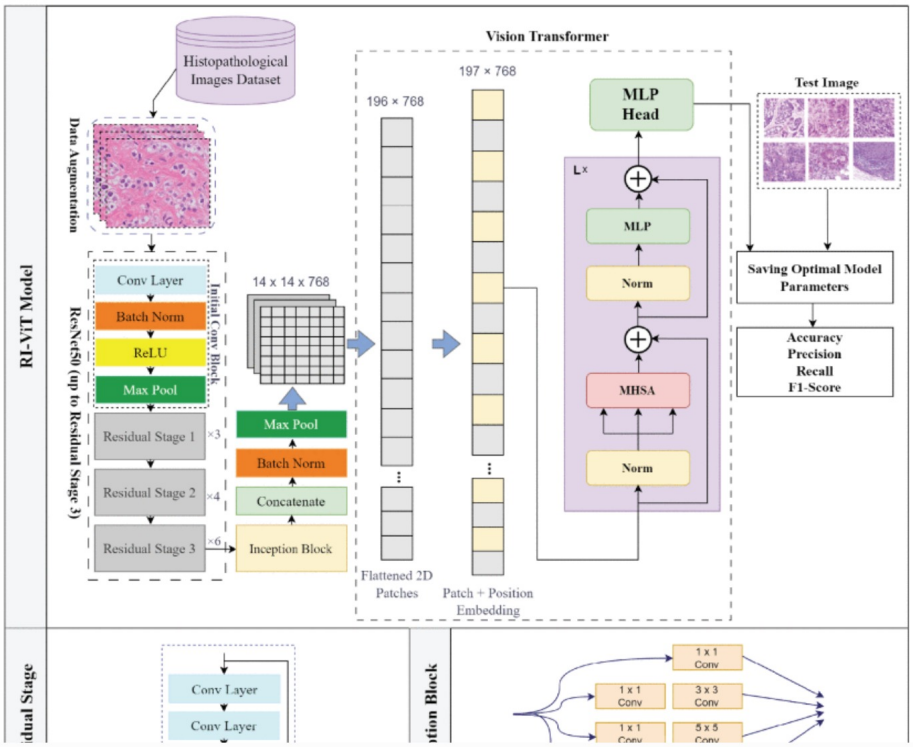


Figure 3: Schema arhitecturii hibride utilizate pentru clasificarea mamografiilor. Imagine preluată din [5].

2.6 Deep Learning Radiomics

Un alt aspect important în determinarea riscului de MGLA este identificarea unor trăsături clare din imagine: forma, sfericitatea, entropia sau chiar asimetria. Toate acestea se pot obține prin intermediul radiometriei, aceasta folosind formule matematice și statistice.

Cu toate acestea, analiza imaginilor ecografice prin intermediul radiomicii prezintă anumite limitări, printre care se numără segmentarea regiunilor de interes și extragerea trăsăturilor predefinite. Radiomica bazată pe Deep Learning, o metodă recent dezvoltată, poate furniza caracteristici cantitative și de mare randament (high-throughput) din

imaginile medicale, prin intermediul învățării supervizate [7]. Astfel, această metodă a fost demonstrat a fi utilă în predicției de fribroză hepatică pe baza analizării imaginilor SWE (Shear Wave Elastography).

Acest articol [3] prezintă rezultatele obținute în cadrul unui studiu în care s-a utilizat Deep Learning Radiomics (soluția hibridă dintre radiomică și Deep Learning) pentru prezicerea de MGLA - AUC de 95%.

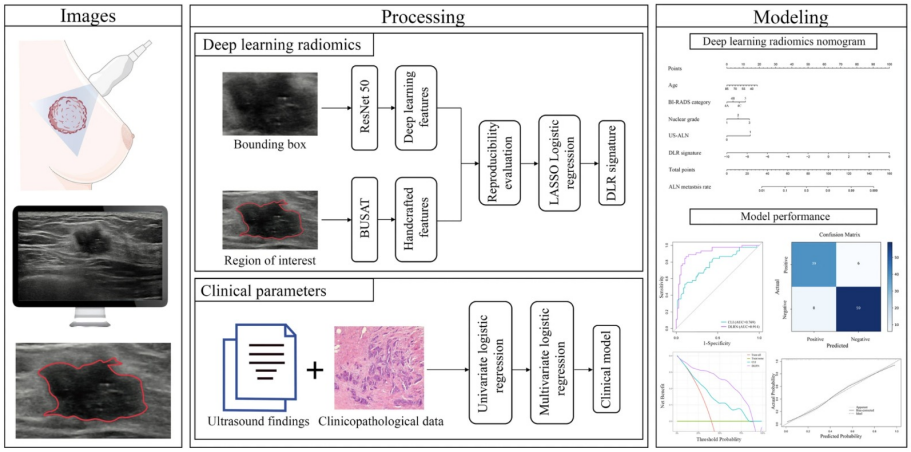


Figure 4: Imagine preluată din [3].

3 Implementări

3.1 Intermediate Fusion între ResNet-50 și ClinicalBERT

Pentru o implementare inițială, am utilizat un set de date care oferă atât mamografii în format digital, cât și fișe medicale asociate. În acest caz, am avut nevoie de 2 modele de machine learning care să rezolve diferite task-uri:

1. ResNet-50 pentru procesarea imaginilor

2. ClinicalBERT pentru procesarea textului medical

Pentru procesarea imaginilor am ales să mergem pe modelul ResNet-50, deoarece acesta este capabil să extragă trăsături fine, esențiale în cadrul analizei noastre, și pentru că este un model stabil. ResNet-50 se bazează pe modelul rețelelor neuronale convolutive, aducând în plus ideea de conexiuni reziduale. Acestea au un rol foarte important în învățarea rapidă a modelului, precum și în păstrarea detaliilor care, în alte situații, s-ar fi pierdut din cauza trecerii imaginii prin straturile rețelei neuronale.

În cazul fișelor medicale a trebui să alegem alt model, de data aceasta care să fie capabil să proceseze texte. Din acest motiv, atenția noastră s-a orientat inițial către BERT, un model specializat pe language processing, bazat pe Transformers. Totuși, fiind vorba de un limbaj medical, acest model nu reușea să surprindă cel mai bine contextul general al fișei, așa că am optat pentru ClinicalBERT. ClinicalBERT este acea varianta a modelului de bază care e preantrenată pe limbaj medical, făcând mult mai ușoară înțelegerea situației descrise de medic în fișa pacientului.

Totuși, deși am utilizat două modele foarte bune pe task-urile lor individuale, rămâne să discutăm despre cum am reușit să combinăm rezultatele date de ambele. Răspunsul este prin Intermediate Fusion. Mai exact, nu folosim predicțiile finale date de ResNet-50 sau de ClinicalBERT, ci embedding-urile de pe penultimul strat, pe care le alăturăm și le dăm mai departe unui clasificator, responsabil pentru luarea ultimei decizii.

A fost făcută o comparație între 2 tipuri de clasificatoare pentru a alege cea mai bună variantă. Astfel, am luat în considerare un clasificator liniar care, deși în general este o soluție mai puțin riguroasă, s-a potrivit în acest context destul de bine. Totuși am vrut să testăm

și implementarea unui Multi-Layer Perceptron (MLP), soluție care în teorie ar trebui să ofere un rezultat mai bun, dar care va consuma mai multe resurse.

Clasificator	Acuratețe	Precizie	Recall	F1 Score	Medie Train Loss	Medie Val Loss
Liniar	0.9200	0.8667	0.9286	0.8966	0.2076	0.29095
MLP	0.9268	0.8667	0.9286	0.8966	0.2316	0.27296

Table 1: Rezultatele comparației dintre clasificatorul liniar și MLP

References

[1] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. 2021.

[2] Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C. Berg, Wan-Yen Lo, Piotr Dollár, and Ross Girshick. Segment anything. 2023.

[3] Han Liu, Liwen Zou, Nan Xu, Haiyun Shen, Yu Zhang, Peng Wan, Baojie Wen, Xiaojing Zhang, Yuhong He, Luying Gui, and Wentao Kong. Deep learning radiomics based prediction of axillary lymph node metastasis in breast cancer. *npj Breast Cancer*, 10(1):22, 2024.

[4] Emergent Mind. Cross-attention layers for feature fusion. 2023.

[5] Ehsan Monjezi, Gholamreza Akbarizadeh, and Karim Ansari-Asl. Ri-vit: A multi-scale hybrid method based on vision transformer for breast cancer detection in histopathological images. *IEEE Access*, 12:186074–186086, 2024.

[6] S. Niu et al. A statistical classifier based on clinical and ultrasound characteristics for predicting axillary lymph node metastasis in operable breast cancer. *Medicine*, 98(40), 2019. PMCID: PMC6783158.

[7] Xueyi Zheng, Zhao Yao, Yini Huang, Yanyan Yu, Yun Wang, Yubo Liu, Rushuang Mao, Fei Li, Yang Xiao, Yuanyuan Wang, Yixin Hu, Jinhua Yu, and Jianhua Zhou. Deep learning radiomics can predict

axillary lymph node status in early-stage breast cancer. *Nature Communications*, 11(1):1236, 2020.